영화 리뷰 극성 분류 → 감정 분류

KoELECTRA 2단계 학습 실험 결과 · NLP 미니프로젝트 #1

[조 이름] · [팀원 이름]

한눈에 보기

91.09%

극성 분류 재현

NSMC test 정확도 (보고치 90.63%)

0.6734

직접 학습

test macro F1 · 2단계 학습은 0.6656

0.6756

최종 모델

test macro F1 · threshold 튜닝 후

88.9%

극성 일관성

부정 리뷰에 부정 계열 감정 (긍정 → 기쁨 82.5%)

NSMC를 먼저 거치는 2단계 학습은 직접 학습보다 나아지지 않았다 — 차이 0.008은 시드 간 표준편차 수준

"별로다"만으로는 왜 별로인지 알 수 없다

Before · 극성 분류

“시간 아깝다 진짜 노잼”

→ 부정

“결말이 너무 어이없어서 화가 난다”

→ 부정

After · 감정 분류

“시간 아깝다 진짜 노잼”

→ 지루함 0.96 · 분노 0.97 · 슬픔 0.94

“결말이 너무 어이없어서 화가 난다”

→ 분노 0.99 · 슬픔 0.95

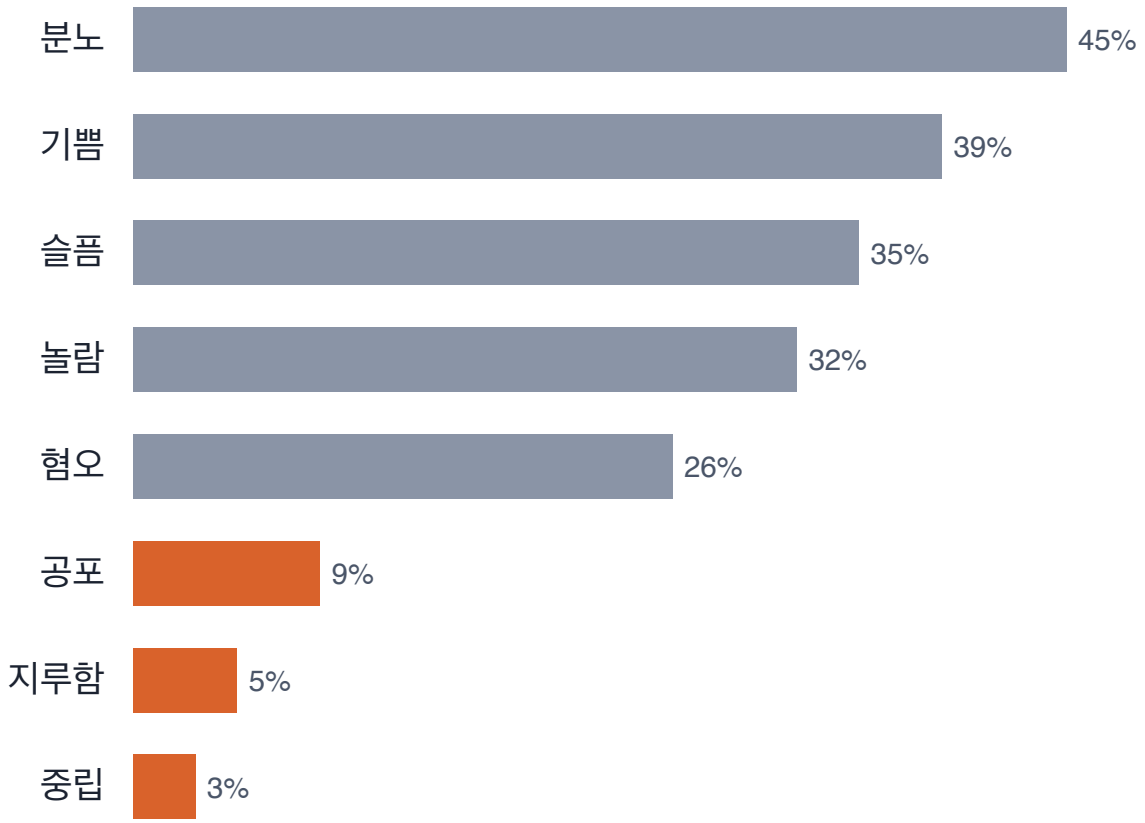
같은 모델 구조에서 출력과 학습 순서를 바꿨다

바뀐 지점	Before · 극성 분류	After · 감정 분류
출력 수	2 (부정, 긍정)	8 (기쁨·슬픔·분노·공포·놀람·혐오·지루함·중립)
활성화 · 손실	softmax + cross-entropy (하나만 고름)	sigmoid + BCE (범주마다 따로 판단)
정답 형태	정수 0/1	8칸 0/1 벡터 (다중 라벨)
학습 순서	사전학습 → NSMC	사전학습 → NSMC → KOTE (2단계 학습)
출력 규칙	—	다른 범주가 켜지면 중립을 끈다 (배타 규칙)

모델: monologg/koelectra-base-v3-discriminator (ELECTRA 판별기 인코더 + 분류 헤드)

KOTE 44개 세부 감정을 8개 감정 범주로 묶었다

범주별 댓글 비율 (train, 한 댓글에 여러 범주 가능)



KOTE

온라인 댓글 5만 건, 44개 감정, 평가자 5명 (영화 리뷰 포함 12개 출처)

정답 기준

평가자 5명 중 2명 이상이 고른 감정만 인정

사용 데이터

train 38,687 · val 4,835 · test 4,844 (제외 라벨만 가진 3%는 뺌)

소수 범주

지루함 5% · 중립 3%: macro F1을 끌어내릴 수 있음

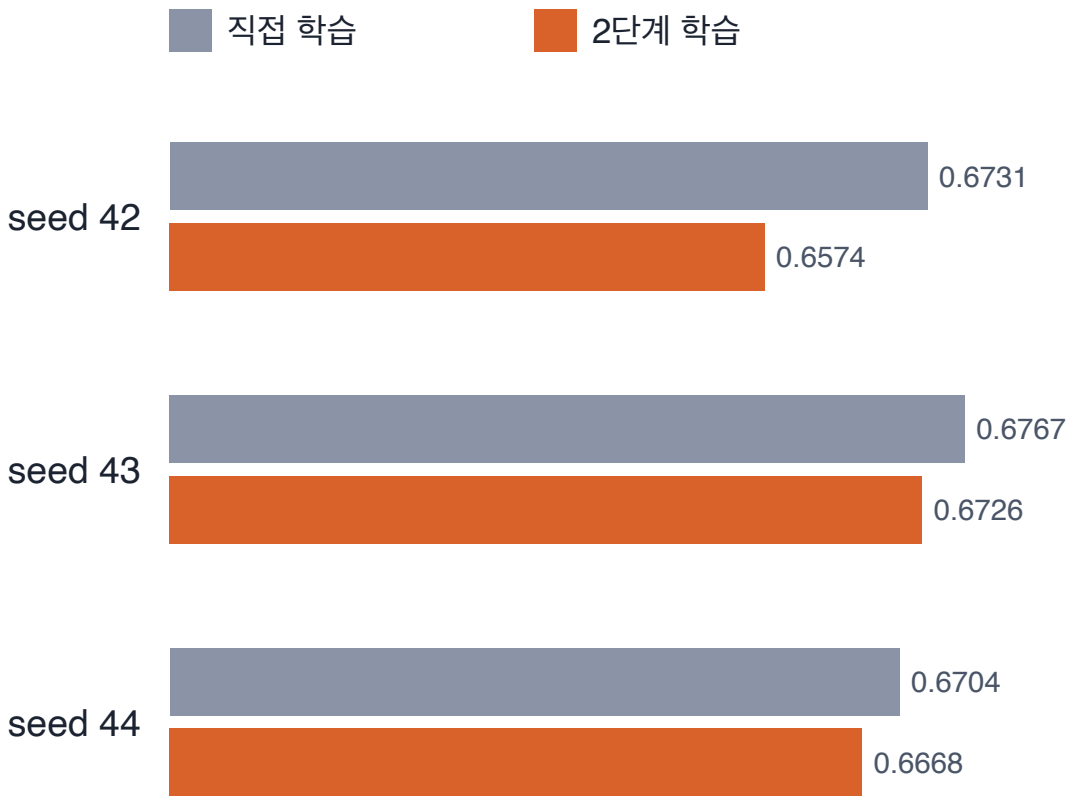
두 방식의 차이는 인코더 가중치 하나뿐이다



- 같은 시드면 헤드 초기값이 같다 → 차이는 인코더 하나
- 공통: lr 5e-5 · batch 64 · max_len 128 · 시드 42/43/44 · val macro F1로 best epoch 선택
- 평가: KOTE test macro F1 (주), 범주별 F1, threshold 0.5, 배타 규칙 적용

2단계 학습은 직접 학습보다 나아지지 않았다

시드별 test macro F1 (막대는 0.60부터)



직접 학습

0.6734 ± 0.0032

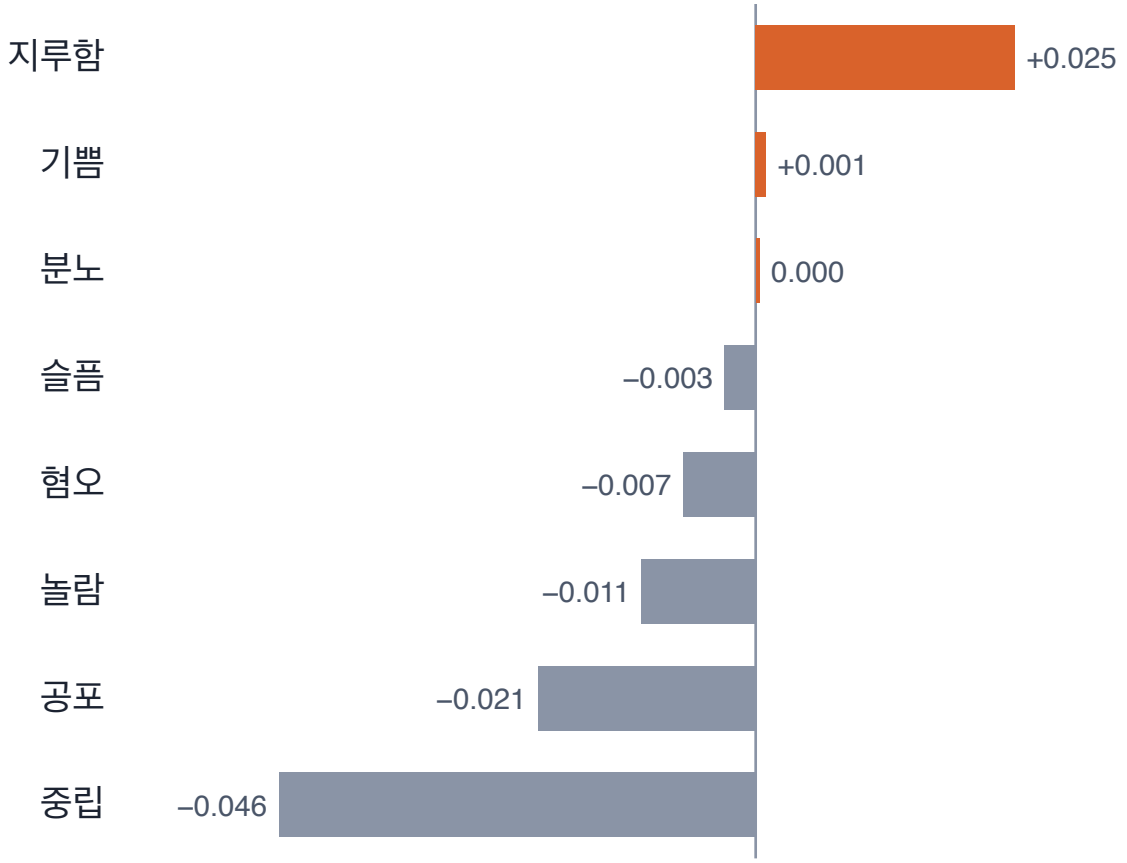
2단계 학습

0.6656 ± 0.0076

차이 0.008 ≈ 2단계 학습의 표준편차.
시드 3개로는 차이가 있다고 단정하기 어렵고, 2단계 학습은 시드 간 편차도 더 컸다.

극성 학습은 지루함을 돕고, 극성과 무관한 감정은 흐렸다

범주별 test F1 차이 (2단계 – 직접, 시드 평균)



이득

지루함 +0.025

영화 도메인의 대표 부정 감정("노잼")은 극성 축과 잘 맞는다

손해

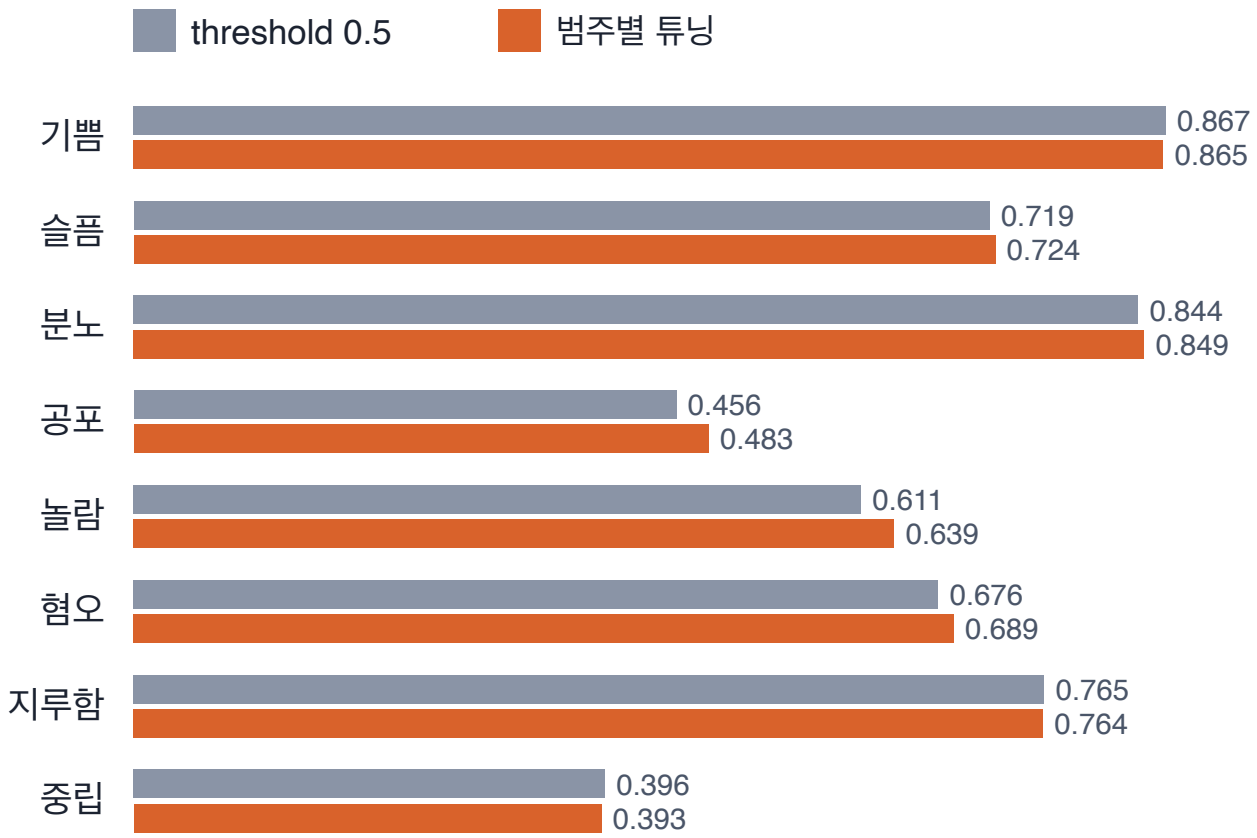
중립 –0.046 · 공포 –0.021

놀람(–0.011)까지, 긍정/부정으로 구분되지 않는 감정이 극성 축에 묻혔다

해석은 범주별 수치에서 세운 가설 (따로 검증하지 않음)

최종 모델: 범주별 threshold 튜닝으로 0.6756

최종 모델(2단계 학습 seed 44) 범주별 test F1



test macro F1

0.6668 → 0.6756

판정 없음

3.5% → 0.7%

크게 오른 범주

놀람 +0.028 · 공포 +0.027

중립은 튜닝해도 나아지지 않았다

4 → 43

중립과 다른 범주가 함께 켜진 test 행 (배타 규칙 적용 전)

0.453 → 0.402

val 중립 F1 (규칙 적용 후)

- 중립 threshold를 0.3으로 낮추자 다른 감정과 함께 켜지는 일이 늘었다
- 배타 규칙이 그 중립을 끄면서 튜닝 효과가 사라졌다
- 범주별 독립 튜닝과 "중립은 혼자만 붙는다"는 정의가 서로 맞지 않는 지점

향후 과제: 배타 규칙을 반영한 threshold 탐색, 또는 "다른 7개가 모두 꺼졌을 때" 중립을 판정하는 전용 규칙

같은 "부정"도 지루함과 분노로 갈린다

리뷰	NSMC 극성	예측 감정 범주 (확률)
배우들 연기가 미쳤다. 두 번 봐도 또 보고 싶음	긍정	기쁨 1.00 · 놀람 0.64
시간 아깝다 진짜 노잼	부정	분노 0.97 · 지루함 0.96 · 슬픔 0.94 · 혐오 0.35
결말이 너무 어이없어서 화가 난다	부정	분노 0.99 · 슬픔 0.95 · 지루함 0.67 · 놀람 0.46
마지막 장면에서 펑펑 울었다	긍정	기쁨 0.88 · 슬픔 0.83
중간에 깜짝 놀라서 소리 질렀음	긍정	놀람 0.95
연출은 좋은데 너무 길어서 졸렸다	—	슬픔 0.96 · 분노 0.93 · 지루함 0.89
사랑한다는 말을 하지않아도...	긍정	기쁨 0.25 (약함 · 판정 없음)

부정 리뷰에 슬픔·분노가 함께 켜지는 일이 많다 — 대응표에서 "안타까움/실망"은 슬픔, "불평/불만"은 분노로 묶었기 때문으로 보인다

영화 리뷰의 극성과 예측 감정이 대체로 맞물린다

82.5%

NSMC 긍정 리뷰 중 기쁨이 켜진 비율

부정 계열도 함께 켜짐 23.1%

88.9%

NSMC 부정 리뷰 중 분노·슬픔·혐오·지루함이 켜진 비율

기쁨이 켜짐 8.3%

어긋난 리뷰 387 / 4,000건 (9.7%)

"ㅋㅋㅋㅋ아웃겨죽겟네 ㅋㅋ"
NSMC 부정 → 기쁨: NSMC 라벨 잡음

"평점 왜이렇게 안좋지;; 개인적으로 엄청 재미있게 봤거든요"
NSMC 긍정 → 슬픔·분노: 평점에 대한 불만을 감정으로 읽음

KOTE 댓글로만 감정을 배웠는데도 영화 리뷰에서 극성과 일관된 감정을 낸다 (극성별 2,000건)

결론과 한계

- 극성 분류(2개)를 8개 감정 범주 다중 라벨 분류로 확장했다 — 최종 모델 test macro F1 0.6756
- NSMC를 거치는 2단계 학습의 이득은 없었다: 지루함은 올랐고 중립·공포·놀람은 내려갔다
- 한계: 시드 3개(통계 검정 없음), 중립 threshold 불안정, KOTE 라벨 잡음, 영화 리뷰는 KOTE 12개 출처 중 하나
- 향후: 배타 규칙을 반영한 중립 판정, 불균형 보정, NSMC 시드 변동 측정, 영화 리뷰 감정 평가셋